基于视觉-语言-动作(VLA)的具身智能导航Agent

——在AI2-THOR仿真环境中实现多模态目标导航与交互

姓　　名：李伟嘉、孙凯、王竣
学　　号：23336118、23336212、23336227
院　　系：计算机学院
专　　业：计算机科学与技术
指导教师：刘阳
日　　期：2026年 5月 6日

---

1. 任务定义与应用背景

1.1 应用背景

具身智能(Embodied AI)是人工智能从"被动感知"走向"主动交互"的关键方向。传统的视觉-语言模型(VLM)如CLIP、BLIP等擅长图像理解与问答，但它们停留在"看和说"的层面，无法在物理环境中执行动作。而具身智能Agent需要在三维环境中，综合视觉观测、语言指令和自身状态，规划并执行一系列物理动作来完成用户指定的任务。

典型应用场景包括：

- **家庭服务机器人**：如"去厨房把苹果拿给我"、"走到红色沙发旁边"
- **仓储物流导航**：在复杂室内环境中根据自然语言指令到达目标位置
- **远程遥操作**：通过语言指令指导机器人在危险或不可达环境中执行任务

这些场景的核心挑战是**多模态对齐与决策**——Agent需要将视觉特征、语言语义和动作空间统一到一个可学习的框架中。

1.2 任务定义

本项目在AI2-THOR仿真环境中构建一个**"视觉+语言"导航Agent**，具体定义如下：

输入：

- 自然语言指令L（如："Go to the microwave and pick it up"）
- 第一人称RGB图像观测I（固定为300×300像素）
- Agent自身状态S（3D坐标x,y,z + 朝向角度rotation）

系统需要生成动作序列$A = \{a_1, a_2, \ldots, a_n\}$：

$$a_t = \pi(I_t, L, S_t)$$

其中 π 为 VLA 决策策略函数，动作空间包含移动、旋转、抬头/低头及拾取。

输出：

- 离散动作序列：MoveAhead | RotateLeft | RotateRight | LookUp | LookDown | Pickup

任务类型：

1. **ObjectNav（目标导航）**：给定目标物体类别（如"microwave"），Agent需导航至该物体可视范围内（距离≤1.5m且无障碍）
2. **Pickup（拾取交互）**：在到达目标物体后，执行拾取动作

成功判定：

- ObjectNav：目标物体在Agent视野内且距离≤1.5m
- Pickup：目标物体被成功拿起

1.3 技术挑战

1. **多模态特征对齐**：视觉(图像)、语言(指令)、状态(位置)三种异构特征如何融合
2. **长程决策规划**：导航需要数十步的连续决策，存在信用分配(credit assignment)难题
3. **泛化能力**：训练在有限场景，测试需泛化到未见过的房间布局和物体摆放

---

2. 相关工作调研

本章重点调研仿真环境平台、视觉语言动作模型、具身导航方法及相关的多模态基础模型。

2.1 仿真环境平台

AI2-THOR (Kolve et al., 2017)

论文：*AI2-THOR: An Interactive 3D Environment for Visual AI*

AI2-THOR提供了4类室内场景（厨房、客厅、卧室、浴室）共122个交互式场景，支持6种离散动作和多种物体交互（打开、拾取、移动等）。其优势在于物理仿真真实、物体交互丰富，且社区活跃。

Habitat-Sim (Chang et al., 2019)

论文：*Habitat: A Platform for Embodied AI Research*[^2]

Habitat-Sim是Facebook Research开发的高性能仿真平台，基于C++底层渲染，速度极快。但在物体交互能力上弱于AI2-THOR，更适合纯导航任务。

对比：

维度	Habitat-Sim	AI2-THOR
渲染速度	极快(C++)	中等(Unity)
交互能力	有限	丰富(开/关/拾取)
场景数量	大量	122个
适合任务	纯导航	导航+交互

本项目选择 **AI2-THOR** 作为基础环境：AI2-THOR 提供了多模态 Agent 必需的物理测试沙盒，本项目中 ObjectNav（目标导航）与 Pickup（拾取）两项核心任务的轨迹数据生成、以及后续的 RL 试错交互均深度依托该平台进行。

2.2 视觉-语言-动作(VLA)模型

RT-2 (Brohan et al., Google DeepMind, 2023)

论文：*RT-2: Vision-Language-Action Models Transfer Web Knowledge to Robotic Control*

RT-2是VLA模型的里程碑工作，将PaLM-E视觉语言模型直接输出机器人动作token，实现了从互联网知识到机器人控制的迁移。其核心思想是将动作空间离散化为token，与文本token统一处理。**本项目借鉴这一思路**，将 AI2-THOR 环境中的 6 种离散动作（如 MoveAhead, Pickup 等）映射为特殊 Token，并通过基座大模型进行自回归输出提供了最直接的设计范式。

RoboCat (Google DeepMind, 2023)

论文：*RoboCat: A Self-Improving Base Agent for Generalist Robotics*

RoboCat展示了通过大规模异构数据预训练+少量新任务微调的范式。虽然本项目数据规模有限，但其利用专家演示数据进行初始对齐、再结合环境交互数据的思路，启发了本项目 **SFT（监督微调）+ PPO（强化学习）**的两阶段训练架构。

2.3 具身导航方法

DD-PPO (Wijmans et al., 2019)

论文：*DD-PPO: Learning Near-Perfect PointGoal Navigators from 2.5 Billion Parameters*

DD-PPO使用分布式PPO在Habitat-Sim上训练ObjectNav策略，输入为RGB深度图+目标类别embedding，输出4个离散动作。其成功证明了纯RL方法在在海量参数和数据下处理导航任务的强大能力，为本项目第二阶段采用 **PPO算法**优化 Agent 长期回报提供了理论与实践支撑。

CLIPort (Shridhar et al., 2021)

论文：*CLIPort: What and Where Pathways for Robotic Manipulation*

CLIPort结合CLIP的语义理解和空间注意力机制，实现语言指令引导的机器人操作。其"What-Where"双路径设计启发了本项目中CLIP特征与SAM检测的融合方式。

2.4 视觉基础模型

CLIP (Radford et al., OpenAI, 2021)

论文：*Learning Transferable Visual Models From Natural Language Supervision*

CLIP通过4亿图文对预训练，实现了强大的零样本视觉理解能力。**本项目使用CLIP ViT-B/32**提取全局场景语义特征，选择理由：

- 参数量~150M，推理速度快
- 512维特征足够ObjectNav语义需求
- 社区最成熟，文档丰富

SAM / MobileSAM (Kirillov et al., Meta, 2023)

论文：*Segment Anything*

SAM实现了通用的图像分割能力。**本项目使用MobileSAM**（轻量版，~40MB）进行目标物体检测与定位，为Agent提供"目标在哪"的空间信息。

2.5 多模态大语言模型

Qwen3-VL 8B (Qwen Team, 2025)

仓库：https://github.com/QwenLM/Qwen2.5-VL

Qwen3-VL是Qwen系列最新的多模态大模型，基于Qwen3 LLM底座，采用NaViT动态分辨率视觉编码器。相比Qwen2.5-VL 7B，在视觉推理和工具调用能力上有显著提升。

本项目选择Qwen3-VL 8B的理由：

- 开源可商用
- 多模态能力强，支持图像+文本联合推理
- 8B参数量在RTX 4090 (24GB)上可通过QLoRA(4bit)微调
- 原生支持function calling，适合动作输出

---

3. 系统方案设计

3.1 整体架构

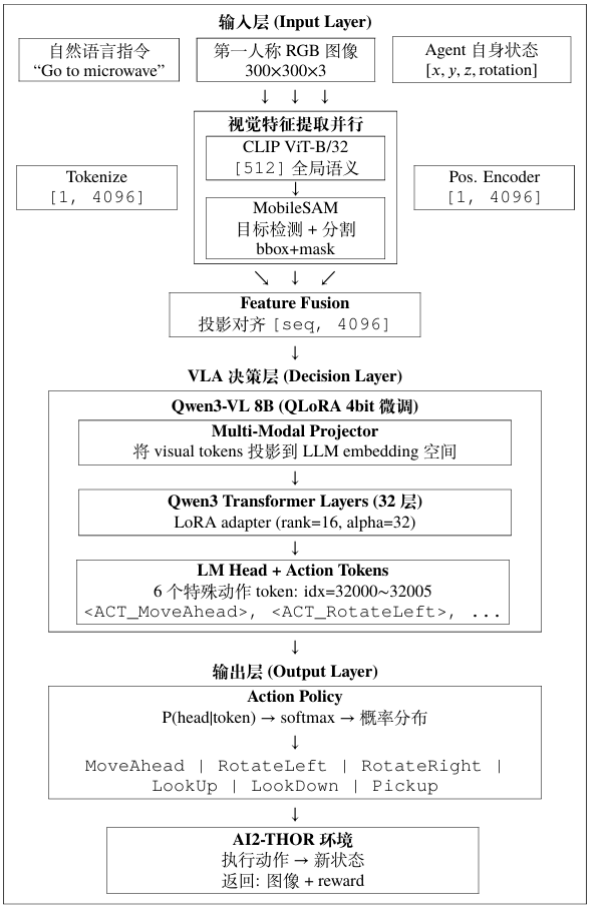

图 3.1　基于 VLA 的具身智能导航 Agent 系统架构图

3.2 各模块详细设计

3.2.1 视觉编码模块

CLIP特征提取器：

- 模型：CLIP ViT-B/32（OpenAI预训练权重）
- 输入：300×300 RGB图像
- 输出：512维全局特征向量
- 作用：捕获场景整体语义（房间类型、物体分布）
- 选择理由：参数量~150M，推理速度快，512维特征对导航任务足够

MobileSAM目标检测：

- 模型：MobileSAM（轻量版SAM，~40MB）
- 输入：300×300 RGB图像 + 目标类别提示（如"microwave"）
- 输出：目标物体的mask + bounding box + 中心点坐标(归一化)
- 作用：提供"目标在哪"的空间定位信息
- 选择理由：完整版SAM推理慢(~0.5s/图)，MobileSAM适合实时导航

特征融合策略：

- CLIP特征通过Linear层投影到4096维（与Qwen hidden dim对齐）
- SAM输出的目标位置编码为2D坐标特征，通过MLP投影
- 最终视觉表示：[num_patches + 1, 4096]

3.2.2 位置编码模块

Agent的3D状态信息对于导航决策至关重要。设计如下：

```
输入: [x, y, z, rotation]  (4维连续值)
  ↓
归一化到 [0, 1] 范围
  ↓
Sinusoidal Positional Encoding (类似Transformer位置编码)
  ↓
Linear(256 → 4096)
  ↓
输出: [1, 4096] 状态特征向量
```

位置特征与视觉特征在输入LLM前进行**拼接融合**，形成完整的环境感知表示。这种设计灵感来自Transformer中的Positional Encoding思想，将连续坐标映射到高维语义空间。

3.2.3 VLA决策模型

基座模型：Qwen3-VL 8B

- 参数量：~8B
- 视觉Encoder：NaViT（动态分辨率）
- 上下文窗口：32K+

- 显存占用（推理FP16）：~16GB
- 显存占用（训练QLoRA）：~16-18GB

QLoRA微调配置（适配RTX 4090 24GB）：

参数	值	说明
量化精度	4bit (NF4)	双重量化节省显存
LoRA rank	16	比16GB方案更高，表达能力更强
LoRA alpha	32	scaling factor
LoRA dropout	0.05	防止过拟合
目标模块	q/k/v/o/gate/up/down_proj	全面覆盖attention和FFN
可训练参数	~7M (0.1%)	冻结大部分参数
batch_size	2 + 梯度累积4	等效batch_size=8
gradient_checkpointing	开启	节省显存

动作token化：
将6个离散动作映射为特殊token，添加到模型词表中：

```
<ACT_MoveAhead>   idx=32000
<ACT_RotateLeft>  idx=32001
<ACT_RotateRight> idx=32002
<ACT_LookUp>      idx=32003
<ACT_LookDown>    idx=32004
<ACT_Pickup>      idx=32005
```

在SFT阶段，模型学习从上下文预测正确的动作token。在PPO阶段，模型输出这些token的概率分布，通过采样或argmax选择动作。

3.2.4 训练策略：SFT + PPO两阶段

第一阶段：监督微调(SFT)

使用启发式策略（A*寻路 + 规则拾取）生成专家演示数据：

- 数据量：~5000条轨迹（每条平均10-20步），约75,000个(state, action)样本
- 损失函数：交叉熵（预测动作 vs 专家动作）
- 训练轮数：3 epochs
- 学习率：2e-4，warmup比例3%
- 目标：让模型学会"基本导航能力"

演示数据生成流程：

1. **导航**：A*算法计算最短路径（利用环境ground truth地图）
2. **拾取**：当目标距离≤1.5m时执行Pickup
3. **数据增强**：对同一轨迹添加噪声（随机偏离1-2步）增加多样性

第二阶段：PPO强化学习

在SFT基础上继续训练，优化长期回报：

- 算法：PPO-Clip（稳定版）
- 折扣因子 γ = 0.99
- GAE参数 λ = 0.95
- Clip范围 ε = 0.2
- 价值损失系数 0.5，熵正则系数 0.01

奖励函数设计：

事件	奖励值	说明
到达目标	+10.0	成功导航到目标物体附近（距离≤1.5m）
成功拾取	+5.0	成功执行Pickup动作
每走一步	-0.1	鼓励最短路径，避免无限徘徊
靠近目标	+0.05/步	距离每缩短1m给予奖励
远离目标	-0.05/步	距离每增加1m给予惩罚
碰撞/越界	-1.0	非法动作惩罚

3.3 评测指标

主要指标

1. 成功率 (Success Rate, SR)

$$SR = \frac{N_{success}}{N_{total}}$$

任务成功（到达目标+拾取成功）的episode占总episode的比例。

2. SPL (Success weighted by Path Length)

$$SPL = \frac{1}{N}\sum_{i=1}^{N} S_i \cdot \frac{l_i^*}{\max(l_i^*, l_i)}$$

其中 S_i 为第i个episode是否成功(0/1)，l_i^* 为最短路径长度，l_i 为Agent实际路径长度。

SPL同时衡量成功率和路径效率，是导航任务的标准指标（Anderson et al., 2018）。

次要指标

指标	定义	说明
平均步数	成功episode的平均动作数	衡量导航效率
路径效率	l^*/l	实际路径与最优路径比值，越接近1越好
泛化率	未见场景的成功率 / 已见场景成功率	衡量模型泛化能力

消融实验设计

实验组	视觉输入	语言指令	位置信息	对比目的
Baseline-A	CLIP特征	✗	✓	纯视觉导航（无语言理解）
Baseline-B	CLIP+SAM	✓	✗	无位置编码的影响
Ours	**CLIP+SAM**	**✓**	**✓**	**完整模型**

通过对比三组实验，验证"视觉+语言+位置"多模态融合的有效性。

---

4. 初步数据集与实验设想

4.1 数据集设计

训练场景

从AI2-THOR的122个场景中选择15个中等复杂度的场景进行训练：

场景类型	场景ID范围	数量	复杂度
厨房	FloorPlan1-5, 201-205	5	中
客厅	FloorPlan1-5, 301-305	5	中
卧室	FloorPlan1-5, 401-405	5	中

测试场景

- **Seen**：训练集中的15个场景（检验拟合能力）
- **Unseen**：额外15个未见过的场景（检验泛化能力）

任务指令模板

ObjectNav指令模板（增加语言多样性）：

- "Go to the {target_object}"
- "Find the {target_object}"
- "Navigate to the {target_object}"
- "Walk over to the {target_object}"

Pickup指令模板（导航后）：

- "Pick up the {target_object}"
- "Grab the {target_object}"

目标物体选择：选择AI2-THOR中常见的10类物体：
Microwave, Fridge, TV, Laptop, Sofa, Chair, Bed, Sink, Toilet, Lamp

演示数据生成

使用启发式策略生成SFT数据：

1. **导航**：A*算法计算最短路径（利用环境ground truth地图）
2. **拾取**：当目标距离≤1.5m时执行Pickup
3. **数据增强**：对同一轨迹添加噪声（随机偏离1-2步）增加多样性

预计数据量：~5000条轨迹 × 15步/条 ≈ 75,000个(state, action)样本

4.2 算力预算

硬件需求

组件	规格	用途
GPU	RTX 4090 (24GB)	模型训练（QLoRA微调）
CPU	8核以上	AI2-THOR环境仿真（较重）
内存	32GB	数据加载+环境运行
存储	50GB	模型权重(~16GB) + 数据 + 日志

训练时间估算

阶段	每步时间	总步数	预估时间
SFT	~2ms	75,000 × 3 epochs	~8小时
PPO	~5ms	50,000 steps	~10小时
评估	~1s/episode	300 episodes	~5分钟

4.3 时间计划

周次	任务	交付物
第9-10周	开题报告与展示	开题报告PDF + 展示PPT
第11-12周	环境搭建与数据处理	AI2-THOR wrapper + SFT数据集
第13-14周	模型实现与SFT训练	CLIP+SAM特征提取 + SFT loss收敛
第15周	PPO训练与调优	PPO训练曲线 + 初步成功率
第16-17周	评估与消融实验	SR/SPL指标 + 可视化 + 失败分析
第18周	最终报告与期末展示	10-15页报告 + 演示视频

4.4 风险与应对

风险	概率	影响	应对方案
AI2-THOR在WSL上运行不稳定	中	高	使用headless模式；备用Docker方案
Qwen3-VL 8B显存不足	低	中	降低LoRA rank至8；或使用Qwen2.5-VL 3B
PPO训练不收敛	中	高	增加SFT数据量；调整奖励函数；使用GAE
训练时间超出预算	中	中	减少场景数量；使用云平台(AutoDL)

4.5 预期成果

1. **代码仓库**：完整的训练+评估+可视化代码（GitHub公开仓库）
2. **量化指标**：
   - ObjectNav成功率：>50% (seen), >30% (unseen)
   - SPL：>0.3 (seen), >0.2 (unseen)
3. **可视化**：10+ episode轨迹图（matplotlib）、失败案例分类统计
4. **消融实验**：证明"视觉+语言+位置"融合相比基线的有效性
5. **最终报告**：10-15页，包含方法、实验、分析
6. **演示视频**：3-5分钟，展示Agent在仿真环境中的导航过程

参考文献

1. [AI2-THOR] Kolve, E., et al. "AI2-THOR: An Interactive 3D Environment for Visual AI." *arXiv preprint arXiv:1712.05474* (2017).
2. [RT-2] Brohan, A., et al. "RT-2: Vision-Language-Action Models Transfer Web Knowledge to Robotic Control." *arXiv preprint arXiv:2307.15818* (2023).
3. [DD-PPO] Wijmans, E., et al. "DD-PPO: Learning Near-Perfect PointGoal Navigators from 2.5 Billion Parameters." *arXiv preprint arXiv:1907.04969* (2019).
4. [CLIP] Radford, A., et al. "Learning Transferable Visual Models From Natural Language Supervision." *ICML* (2021).
5. [SAM] Kirillov, A., et al. "Segment Anything." *ICCV* (2023).
6. [CLIPort] Shridhar, M., et al. "CLIPort: What and Where Pathways for Robotic Manipulation." *CoRL* (2021).
7. [SPL Metric] Anderson, P., et al. "On Evaluation of Embodied Navigation Agents." *arXiv preprint arXiv:1807.06649* (2018).
8. [RoboCat] Google DeepMind. "RoboCat: A Self-Improving Base Agent for Generalist Robotics." (2023).
9. [Qwen-VL] Qwen Team. "Qwen2.5-VL / Qwen3-VL Technical Report." (2025).
10. [Habitat] Chang, A., et al. "Habitat: A Platform for Embodied AI Research." *ICCV* (2019).