基于视觉-语言-动作 (VLA) 的具身智能导航 Agent

——在 AI2-THOR 仿真环境中实现多模态目标导航与交互

Embodied Intelligent Navigation Agent Based on Vision-Language-Action (VLA)

姓　　名	李伟嘉、孙凯、王竣
学　　号	23336118 23336212 23336227
院　　系	计算机学院
专　　业	计算机科学与技术
指导教师	刘阳

2026 年 5 月 6 日

【摘　要】

随着人工智能从”被动感知”向”主动交互”演进，具身智能（Embodied AI）成为当前研究的前沿热点。本项目旨在设计并实现一个基于视觉-语言-动作（VLA）模型的智能导航 Agent，使其能在 AI2-THOR 仿真环境中根据自然语言指令完成目标导航（ObjectNav）与物体交互（Pickup）任务。系统采用 Qwen3-VL 8B 作为核心决策引擎，结合 CLIP 全局特征与 MobileSAM 局部空间信息，构建了多模态融合的感知框架。项目设计了监督微调（SFT）与近端策略优化（PPO）两阶段训练策略，通过将专家演示数据与强化学习回报相结合，提升 Agent 在长程决策中的鲁棒性与泛化能力。实验拟在 30 个室内场景中对系统进行评测，采用成功率（SR）与路径长度加权成功率（SPL）作为核心评价指标。研究成果对于提升家庭服务机器人、智能仓储等场景的自主交互水平具有重要意义。

关键词：具身智能，视觉-语言-动作模型，AI2-THOR，Qwen3-VL，强化学习

[ABSTRACT]

As artificial intelligence evolves from passive perception to active interaction, Embodied AI has become a frontier research hotspot. This project aims to design and implement an intelligent navigation agent based on a Vision-Language-Action (VLA) model, enabling it to perform Object Navigation (ObjectNav) and object interaction (Pickup) tasks in the AI2-THOR simulation environment according to natural language instructions. The system uses Qwen3-VL 8B as the core inference engine, combined with CLIP global features and MobileSAM local spatial information to build a multimodal fusion perception framework. A two-stage training strategy consisting of Supervised Fine-Tuning (SFT) and Proximal Policy Optimization (PPO) is designed to enhance the agent's robustness and generalization in long-term decision-making. The experiments are scheduled to evaluate the system in 30 indoor scenes using Success Rate (SR) and Success weighted by Path Length (SPL) as core metrics. The research results are of great significance for improving the autonomous interaction level in scenarios such as home service robots and intelligent warehousing.

Key Words: Embodied AI; Vision-Language-Action Model; AI2-THOR; Qwen3-VL; Reinforcement Learning

目　　录

第 1 章　任务定义与应用背景 1
1.1　应用背景 1
1.2　任务定义 1
1.3　技术挑战 2
1.4　本项目特色与创新点 2

第 2 章　相关工作调研 3
2.1　仿真环境平台 3
2.2　视觉-语言-动作 (VLA) 模型 3
2.3　具身导航方法 4
2.4　视觉与多模态大语言底座 4

第 3 章　系统方案设计 6
3.1　整体架构 6
3.2　各模块详细设计 7
3.3　训练策略：SFT + PPO 两阶段 8
3.4　评测指标 9

第 4 章　初步数据集与实验设想 11
4.1　数据集设计 11
4.2　算力预算 11
4.3　消融实验设想 12
4.4　时间计划与项目执行规划 12
4.5　风险与应对 12
4.6　预期成果 13

参考文献 14

第 1 章　任务定义与应用背景

1.1　应用背景

具身智能（Embodied AI）是人工智能从” 被动感知” 走向” 主动交互” 的关键方向。传统的视觉语言模型（VLM）擅长图像理解与问答，但无法在物理环境中执行动作。而具身智能 Agent 需要在三维环境中，综合视觉观测、语言指令和自身状态，规划并执行一系列物理动作来完成用户指定的任务。

典型应用场景包括：

- **家庭服务机器人**：如” 去厨房把苹果拿给我”、” 走到红色沙发旁边”；
- **仓储物流导航**：在复杂室内环境中根据自然语言指令到达目标位置；
- **远程遥操作**：通过语言指令指导机器人在危险或不可达环境中执行任务。

这些场景的核心挑战是**多模态对齐与决策**——Agent 需要将视觉特征、语言语义和动作空间统一到一个可学习的框架中。

1.2　任务定义

本项目旨在 AI2-THOR 仿真环境中构建一个**视觉-语言-动作（VLA）导航 Agent**。

1.2.1　问题形式化

给定输入：

- **自然语言指令** L：如：”Go to the microwave and pick it up”
- **第一人称 RGB 图像观测** I：固定为 300x300 像素
- **Agent 自身状态** S：包含 3D 坐标 x,y,z + 朝向角度 rotation

系统需要生成离散动作序列 $A = \{a_1, a_2, ..., a_n\}$：

$$a_t = \pi(I_t, L, S_t) \tag{1.1}$$

其中 π 为 VLA 决策策略函数，动作空间包含移动、旋转、抬头/低头及拾取。

1.2.2　核心任务

1. **ObjectNav（目标导航）**：给定目标物体类别（如”microwave”），Agent 需导航至该物体可视范围内（距离 ≤1.5m 且无障碍）；
2. **Pickup（拾取交互）**：在到达目标物体后，执行拾取动作。

1.3 技术挑战

- **多模态特征对齐**：视觉、语言、状态三种异构特征的深度融合；
- **长程决策规划**：导航需要数十步的连续决策，存在严重的信用分配（credit assignment）难题；
- **泛化能力**：模型需在未见过的房间布局和物体摆放中保持导航效能。

1.4 本项目特色与创新点

1. **基于最新 Qwen3-VL 的 VLA 架构**：选用 2025 年发布的 Qwen3-VL 8B 作为底座，利用其原生支持的多模态指令遵循能力。
2. **双路径视觉感知方案**：结合 CLIP 的全局语义特征与 MobileSAM 的局部空间定位特征，兼顾” 是什么” 和” 在哪里”。
3. **SFT+PPO 两阶段训练**：通过专家演示数据（A* 算法生成）进行行为克隆，再通过强化学习优化路径效率（SPL）。

第 2 章　相关工作调研

本章重点调研仿真环境平台、视觉语言动作模型、具身导航方法及相关的多模态基础模型。

2.1　仿真环境平台

2.1.1　AI2-THOR (Kolve et al., 2017)

论文：AI2-THOR: An Interactive 3D Environment for Visual AI[1]

AI2-THOR 提供了 4 类室内场景（厨房、客厅、卧室、浴室）共 122 个交互式场景，支持 6 种离散动作和多种物体交互（打开、拾取、移动等）。其优势在于物理仿真真实、物体交互丰富，且社区活跃。

2.1.2　Habitat-Sim (Chang et al., 2019)

论文：Habitat: A Platform for Embodied AI Research[2]

Habitat-Sim 由 Facebook Research 开发，基于 C++ 底层渲染，具有极高的渲染速度。但在物体交互能力上弱于 AI2-THOR，更适合纯导航任务。

表 2.1　仿真环境平台对比

维度	**Habitat-Sim**	**AI2-THOR**
渲染速度	极快 (C++)	中等 (Unity)
交互能力	有限	丰富 (开/关/拾取)
场景数量	大量	122 个
适合任务	纯导航	导航 + 交互

本项目选择 **AI2-THOR 作为基础环境**：AI2-THOR 提供了多模态 Agent 必需的物理测试沙盒，本项目中 ObjectNav（目标导航）与 Pickup（拾取）两项核心任务的轨迹数据生成、以及后续的 RL 试错交互均深度依托该平台进行。

2.2　视觉-语言-动作 (VLA) 模型

2.2.1　RT-2 (Google DeepMind, 2023)

论文：RT-2: Vision-Language-Action Models Transfer Web Knowledge to Robotic Control[3]

RT-2 是 VLA 模型的里程碑工作，将 PaLM-E 视觉语言模型直接输出机器人动

作 token，实现了从互联网知识到机器人控制的迁移。其核心思想是将动作空间离散化为 token，与文本 token 统一处理。本项目借鉴这一思路，将 AI2-THOR 环境中的 6 种离散动作（如 MoveAhead, Pickup 等）映射为特殊 Token，并通过基座大模型进行自回归输出提供了最直接的设计范式。

2.2.2 RoboCat (Google DeepMind, 2023)

论文：RoboCat: A Self-Improving Base Agent for Generalist Robotics[4]

RoboCat 展示了通过大规模异构数据预训练 + 少量新任务微调的范式。虽然本项目数据规模有限，但其利用专家演示数据进行初始对齐、再结合环境交互数据的思路，启发了本项目 **SFT（监督微调）+ PPO（强化学习）**的两阶段训练架构。

2.3 具身导航方法

2.3.1 DD-PPO (Wijmans et al., 2019)

论文：DD-PPO: Learning Near-Perfect PointGoal Navigators from 2.5 Billion Parameters[5]

DD-PPO 使用分布式 PPO 在 Habitat-Sim 上训练 ObjectNav 策略，证明了纯 RL 方法在海量参数和数据下处理导航任务的强大能力，为本项目第二阶段采用 PPO 算法优化 Agent 长期回报提供了理论与实践支撑。

2.3.2 CLIPort (Shridhar et al., 2021)

论文：CLIPort: What and Where Pathways for Robotic Manipulation[6]

CLIPort 结合 CLIP 的语义理解和空间注意力机制，实现语言指令引导的机器人操作。其“What-Where”双路径设计启发了本项目中在视觉前端采用“CLIP 提取全局场景语义 + SAM 提取局部目标掩码”的双流融合机制，该论文论证了这种特征解耦与重组在具身任务中的高效性。

2.4 视觉与多模态大语言底座

2.4.1 CLIP 与 SAM

CLIP (Radford et al., 2021)

论文：CLIP: Learning Transferable Visual Models From Natural Language Supervision[7]

通过大规模图文对比学习实现了强大的零样本视觉理解。本项目使用其 **ViT-**

B/32 版本提取 512 维全局场景语义特征；

MobileSAM (Kirillov et al., 2023)

论文：SAM: Segment Anything[8]

则用于目标物体检测与分割，为 Agent 提供轻量级且实时的“目标在哪”的空间信息。

2.4.2 Qwen3-VL 8B (Qwen Team, 2025)

论文：Qwen-VL: Qwen2.5-VL / Qwen3-VL Technical Report[9]

Qwen3-VL 是最新的多模态大模型，采用 NaViT 动态分辨率视觉编码器。选择其作为基座模型的原因：

- 开源且多模态能力强，支持图文联合推理；
- 8B 参数量在 RTX 4090 (24GB) 上可通过 QLoRA (4bit) 进行微调；
- 原生支持 Function Calling，天然适合转化为动作输出控制。

第 3 章　系统方案设计

3.1　整体架构

系统的整体运行流转围绕“感知-对齐-决策-动作”展开。系统架构详见图3.1。

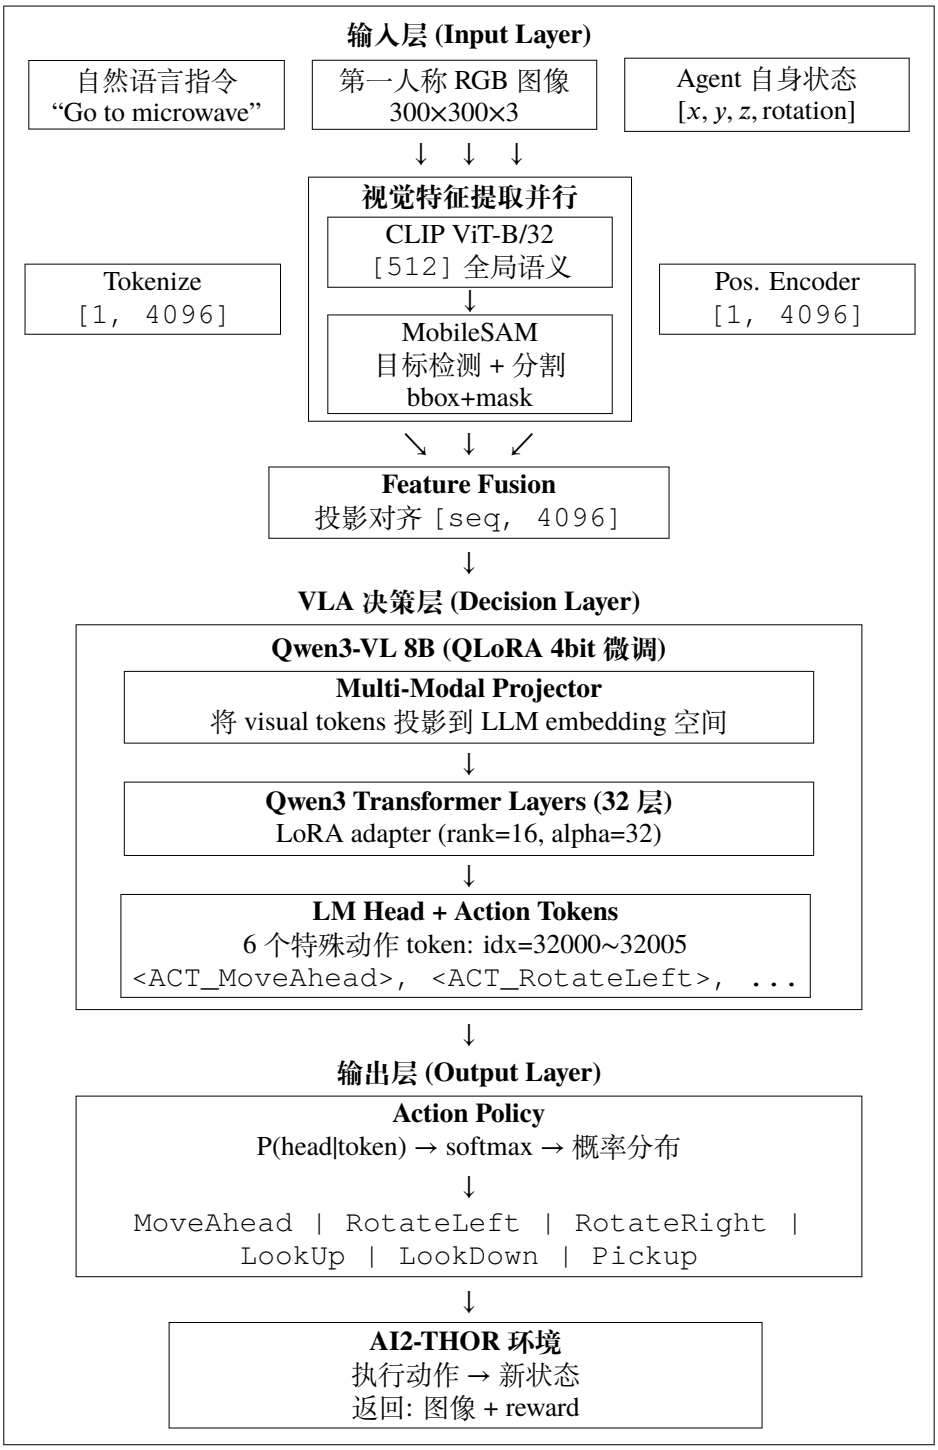

图 3.1　基于 VLA 的具身智能导航 Agent 系统架构图

3.2 各模块详细设计

3.2.1 视觉编码模块

CLIP 特征提取器：

- 模型：CLIP ViT-B/32（OpenAI 预训练权重）
- 输入：300×300 RGB 图像
- 输出：512 维全局特征向量
- 作用：捕获场景整体语义（房间类型、物体分布）
- 选择理由：参数量 ~150M，推理速度快，512 维特征对 ObjectNav 语义需求足够

MobileSAM 目标检测：

- 模型：MobileSAM（轻量版 SAM，~40MB）
- 输入：300×300 RGB 图像 + 目标类别提示（如 “microwave”）
- 输出：目标物体的 mask + bounding box + 中心点坐标 (归一化)
- 作用：提供 “目标在哪” 的空间定位信息
- 选择理由：完整版 SAM 推理慢 (~0.5s/图)，MobileSAM 适合实时导航

特征融合策略：

- CLIP 特征通过 Linear 层投影到 4096 维（与 Qwen hidden dim 对齐）；
- SAM 输出的目标位置编码为 2D 坐标特征，通过 MLP 投影；
- 最终视觉表示为：`[num_patches + 1, 4096]`。

3.2.2 位置编码模块

Agent 的 3D 状态信息对于导航决策至关重要。设计流程如下：

- **输入**: `[x, y, z, rotation]` (4 维连续值) → 归一化到 `[0, 1]` 范围
- **编码**: Sinusoidal Positional Encoding (类似 Transformer 位置编码)
- **映射**: Linear (256 → 4096)
- **输出**: `[1, 4096]` 状态特征向量

位置特征与视觉特征在输入 LLM 前进行**拼接融合**，形成完整的环境感知表示。这种设计灵感来自 Transformer 中的 Positional Encoding 思想，将连续坐标映射到高维语义空间。

3.2.3 VLA 决策模型

基座模型：Qwen3-VL 8B

- 参数量：~8B
- 视觉 Encoder：NaViT（动态分辨率）

- 上下文窗口：32K+
- 显存占用（推理 FP16）：~16GB
- 显存占用（训练 QLoRA）：~16-18GB

QLoRA 微调配置（适配 RTX 4090 24GB）：

表 3.1　QLoRA 微调配置表

参数	值	说明
量化精度	4bit (NF4)	双重量化节省显存
LoRA rank	16	比 16GB 方案更高，表达能力更强
LoRA alpha	32	scaling factor
LoRA dropout	0.05	防止过拟合
目标模块	q/k/v/o/gate/up/down_proj	全面覆盖 attention 和 FFN
可训练参数	~7M (0.1%)	冻结大部分参数
batch_size	2 + 梯度累积 4	等效 batch_size=8
gradient_checkpointing	开启	节省显存

动作 token 化：将 6 个离散动作映射为特殊 token，添加到模型词表中：

```
<ACT_MoveAhead>   idx=32000
<ACT_RotateLeft>  idx=32001
<ACT_RotateRight> idx=32002
<ACT_LookUp>      idx=32003
<ACT_LookDown>    idx=32004
<ACT_Pickup>      idx=32005
```

在 SFT 阶段，模型学习从上下文预测正确的动作 token。在 PPO 阶段，模型输出这些 token 的概率分布，通过采样或 argmax 选择动作。

3.3　训练策略：SFT + PPO 两阶段

3.3.1　第一阶段：监督微调 (SFT)

使用启发式策略（A* 寻路 + 规则拾取）生成专家演示数据：

- 数据量：~5000 条轨迹（每条平均 10-20 步），约 75,000 个 (state, action) 样本
- 损失函数：交叉熵（预测动作 vs 专家动作）
- 训练轮数：3 epochs
- 学习率：2e-4，warmup 比例 3%
- 目标：让模型学会 “基本导航能力”

演示数据生成流程：

1. **导航**：A* 算法计算最短路径（利用环境 ground truth 地图）；

2. **拾取**：当目标距离 ⩽1.5m 时执行 Pickup；
3. **数据增强**：对同一轨迹添加噪声（随机偏离 1-2 步）增加多样性。

3.3.2 第二阶段：PPO 强化学习

在 SFT 基础上继续训练，优化长期回报：

- 算法：PPO-Clip（稳定版）
- 折扣因子 $\gamma = 0.99$
- GAE 参数 $\lambda = 0.95$
- Clip 范围 $\epsilon = 0.2$
- 价值损失系数 0.5，熵正则系数 0.01

奖励函数设计：

表 3.2 PPO 阶段奖励函数设计

事件	奖励值	说明
到达目标	+10.0	成功导航到目标物体附近（距离 ⩽1.5m）
成功拾取	+5.0	成功执行 Pickup 动作
每走一步	-0.1	鼓励最短路径，避免无限徘徊
靠近目标	+0.05/步	距离每缩短 1m 给予奖励
远离目标	-0.05/步	距离每增加 1m 给予惩罚
碰撞/越界	-1.0	非法动作惩罚

3.4 评测指标

3.4.1 主要指标

1. 成功率 (Success Rate, SR)

$$SR = \frac{N_{success}}{N_{total}} \tag{3.1}$$

任务成功（到达目标 + 拾取成功）的 episode 占总 episode 的比例。

2. SPL (Success weighted by Path Length)

论文：SPL: On Evaluation of Embodied Navigation Agents[10]

$$SPL = \frac{1}{N}\sum_{i=1}^{N} S_i \cdot \frac{l_i^*}{\max(l_i^*, l_i)} \tag{3.2}$$

其中 S_i 为第 i 个 episode 是否成功 (0/1)，l_i^* 为最短路径长度，l_i 为 Agent 实际路径长度。SPL 同时衡量成功率和路径效率，是导航任务的标准指标（Anderson et al., 2018）。

3.4.2 次要指标

表 3.3 次要评测指标

指标	定义	说明
平均步数	成功 episode 的平均动作数	衡量导航效率
路径效率	l^*/l	实际路径与最优路径比值，越接近 1 越好
泛化率	未见场景的成功率 / 已见场景成功率	衡量模型泛化能力

3.4.3 消融实验设计

通过对比三组实验，验证 “视觉 + 语言 + 位置” 多模态融合的有效性。

表 3.4 消融实验组别设计

实验组	视觉输入	语言指令	位置信息	对比目的
Baseline-A	CLIP 特征	×	✓	纯视觉导航（无语言理解）
Baseline-B	CLIP+SAM	✓	×	无位置编码的影响
Ours	**CLIP+SAM**	✓	✓	**完整模型**

第 4 章　初步数据集与实验设想

4.1　数据集设计

本实验数据集依托 AI2-THOR 构建，涉及训练集和测试集分离以验证模型的泛化能力。

4.1.1　训练与测试场景划分

- **训练集 (Seen)**：选取厨房、客厅、卧室各 5 个中等复杂度场景（如 FloorPlan1-5 等），共计 15 个场景。
- **测试集 (Unseen)**：额外划定 15 个模型未接触过的房间布局，评估模型泛化能力。

4.1.2　任务指令模板与目标

ObjectNav 指令模板：

- ”Go to the target_object”
- ”Find the target_object”
- ”Navigate to the target_object”
- ”Walk over to the target_object”

Pickup 指令模板：

- ”Pick up the target_object”
- ”Grab the target_object”

目标物体限定于 10 类高频交互物品：Microwave, Fridge, TV, Laptop, Sofa, Chair, Bed, Sink, Toilet, Lamp。

4.2　算力预算

系统微调和强化学习训练需要一定的算力支持，资源评估与耗时预估如下：

表 4.1　训练硬件需求预估

组件	规格	用途
GPU	RTX 4090 (24GB)	模型 QLoRA 微调与 PPO 推理采样
CPU	8 核及以上	AI2-THOR 3D 环境高并发仿真仿真
内存	⩾ 32GB	数据加载与环境运行状态维护
存储	⩾ 50GB	模型权重 (~16GB)、数据集及训练日志存储

训练时间预估：SFT 阶段（7.5 万样本，3 Epochs）预计约 8 小时；PPO 强化学习阶段（5 万 Steps）预计约 10 小时。总体训练开销在单卡 24 小时以内。

4.3 消融实验设想

为了验证多模态特征融合框架的有效性，设计了三组对比实验：

表 4.2 消融实验设计

实验组别	视觉输入	语言指令	位置状态	对比验证目的
Baseline-A	CLIP 提取	×	✓	测试纯视觉导航能力（无指令语义引导）
Baseline-B	CLIP+SAM	✓	×	验证 Agent 本体 3D 空间位置编码的必要性
Ours	**CLIP+SAM**	✓	✓	**验证完整多模态架构的最终表现**

4.4 时间计划与项目执行规划

项目开发周期预计为 10 周（学期后半段），关键里程碑如下：

表 4.3 时间计划表

周次	核心任务	交付物
第 9-10 周	完成课题开题报告与答辩	开题报告 PDF + 汇报 PPT
第 11-12 周	AI2-THOR 环境封装接口与轨迹数据生成	SFT 演示数据集构建完毕
第 13-14 周	视觉模块集成与基座模型 SFT 阶段训练	损失函数收敛曲线图
第 15 周	PPO 算法接入与超参数调优	PPO 阶段奖励（Reward）曲线图
第 16-17 周	在 Unseen 场景中进行评估与消融实验	SR 与 SPL 核心指标表与失败案例分析
第 18 周	撰写总结报告与期末成果展示答辩	完整版项目报告 + 视频演示 Demo

4.5 风险与应对

- **AI2-THOR 运行稳定性**（概率：中）：在 Linux/WSL 渲染容易出错。应对：采用 Headless（无头）渲染模式，备选 Docker 虚拟显示方案。
- **显存溢出 (OOM) 风险**（概率：低）：8B 模型在 RL 采样时消耗较大。应对：动态降低 LoRA Rank 或缩短环境交互的序列最大步数。
- **强化学习不收敛**（概率：中）：奖励分配稀疏。应对：优化 Reward Shaping，增加中间过程的密集奖励（如朝向正确的奖励）。

4.6 预期成果

1. **开源代码库**：提交完整的包含环境封装、SFT+PPO 训练逻辑、评估逻辑的工程代码；
2. **核心指标突破**：预期在已见场景 (Seen) 达成 >50% 的 ObjectNav 成功率，未见场景 (Unseen) 达到 >30%；
3. **科研总结材料**：形成包含方法学、实验分析及图表的规范学术报告，并附带 3-5 分钟具身 Agent 执行任务的可视化演示视频。

参 考 文 献

[1] Kolve E, Mottaghi R, Han W, et al. Ai2-thor: An interactive 3d environment for visual ai[A]. 2017.

[2] Chang A, Dai A, Funkhouser T, et al. Habitat: A platform for embodied ai research[C]. Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). 2019.

[3] Brohan A, Brown N, Carbajal J, et al. Rt-2: Vision-language-action models transfer web knowledge to robotic control[A]. 2023.

[4] Bousmalis K, Rettinghouse G, Chaplin M, et al. Robocat: A self-improving base agent for generalist robotics[J]. Google DeepMind, 2023.

[5] Wijmans E, Kadian A, Morcos A, et al. Dd-ppo: Learning near-perfect pointgoal navigators from 2.5 billion parameters[A]. 2019.

[6] Shridhar M, Manuelli L, Fox D. Cliport: What and where pathways for robotic manipulation[C]. Conference on Robot Learning (CoRL). 2021.

[7] Radford A, Kim J W, Hallacy C, et al. Learning transferable visual models from natural language supervision[C]. International Conference on Machine Learning (ICML). 2021.

[8] Kirillov A, Mintun E, Ravi N, et al. Segment anything[C]. Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). 2023.

[9] Qwen Team. Qwen2.5-vl / qwen3-vl technical report[Z]. 2025.

[10] Anderson P, Chang A, Chaplot D S, et al. On evaluation of embodied navigation agents[A]. 2018.